

PODRĘCZNIK BEZPIECZEŃSTWA AGENTÓW AI (MANUAL)

MODUŁ 1: Bezpieczeństwo Agentów AI i Świadome Projektowanie Systemów

Rozdział 3: Sprawczość i autonomia systemów AI

1. PARADYGMAT AUTONOMII: TRAMWAJ VS SAMOCHÓD TERENOWY

Zrozumienie przejścia od klasycznej automatyzacji do systemów autonomicznych jest kluczowe dla zdefiniowania nowej powierzchni ataku w inżynierii AI.

Klasyczna automatyzacja (Zapier, Make)

Klasyczne systemy automatyzacji procesów działają w sposób deterministyczny – jak tramwaj na szynach.

- **Workflow:** Opiera się na sztywnym algorytmie: **Jeżeli wydarzy się A → wykonaj B → potem C.**
- **Ograniczenia:** Brak adaptacji, brak samodzielnego podejmowania decyzji oraz całkowity paraliż procesu w przypadku wystąpienia anomalii (np. zmiana struktury dokumentu, zmiana API).

Systemy agentowe (Nowa era)

Agent AI wykracza poza sztywne ramy algorytmu – działa jak samochód terenowy. Otrzymuje od architekta jedynie cel główny, po czym samodzielnie wytycza ścieżkę jego realizacji w otwartym i dynamicznym środowisku.

- **Agency (Sprawczość):** Zdolność do autonomicznego planowania, wyboru narzędzi i wykonywania operacji w świecie zewnętrznym (np. samodzielne napisanie, zaadresowanie i wysłanie wiadomości zamiast biernego sugerowania tekstu).

 **Złota Zasada Bezpieczeństwa:** Sprawczość (*Agency*) jest jednocześnie największą zaletą biznesową oraz głównym wektorem zagrożeń. Im większa decyzyjność agenta, tym większa staje się jego **powierzchnia ataku (Attack Surface)** – czyli suma wszystkich punktów i integracji, przez które haker może zmanipulować system.

2. REWOLUCJA KNOWLEDGE RETRIEVAL: WALKA Z HALUCYNACJAMI

Poleganie wyłącznie na wewnętrznych mechanizmach modeli językowych generuje wysokie ryzyko operacyjne.

Pamięć parametryczna (Parametric Memory) a halucynacje

Modele LLM domyślnie operują na wiedzy utrwalonej w procesie ich trenowania. Działają jak student zdający egzamin wyłącznie z pamięci. W przypadku braku precyzyjnych danych, model przejawia tendencję do **halucynacji (Hallucination)** – generuje fałszywe informacje w sposób wysoce przekonujący i logicznie brzmiący.

RAG (Retrieval-Augmented Generation)

Architektura RAG transformuje proces wnioskowania, zmieniając go w "egzamin z otwartą książką". Przed wygenerowaniem odpowiedzi agent przeszukuje podpięte repozytoria, pobiera dokumenty źródłowe i na ich podstawie buduje odpowiedź.

- **Single Source of Truth (SSOT):** Centralne, zweryfikowane źródło prawdy dla agenta, eliminujące domysły, redukujące halucynacje i zapewniające pełną kontrolę nad generowaną treścią.

3. ORKIESTRACJA: NARZĘDZIA A PROCEDURY ROZUMOWANIA

Skuteczna architektura agentowa wymaga precyzyjnego rozdzielenia wykonania od logiki.

- **Narzędzia (Tools):** Komponenty wykonawcze, które realizują konkretne, bezmyślne akcje (np. wykonanie zapytania SQL, wyszukiwarka internetowa, wysyłka maila).
- **Umiejętności agentowe (Agentic Skills):** Procedury wnioskowania i kognitywne schematy myślenia (np. ocena sytuacji w oparciu o politykę firmy przed podjęciem decyzji).
- **Orkiestracja narzędzi (Tool Orchestration):** Dynamiczny proces, w którym agent samodzielnie decyduje, którego narzędzia użyć, kiedy to zrobić oraz w jakiej kolejności, aby optymalnie zrealizować postawiony cel.

4. DEGRADACJA KOGNITYWNA: UKRYTE RYZYKA SYSTEMOWE

Przeciążenie kontekstu agenta prowadzi do bezpośredniego spadku poziomu bezpieczeństwa systemu.

- **Token Bloat (Przeładowanie tokenami):** Nadmierne, niekontrolowane rozrastanie się okna kontekstowego agenta spowodowane wstrzykiwaniem zbyt wielu instrukcji, danych i opisów narzędzi jednocześnie.
- **Obciążenie poznawcze (Cognitive Load):** Stan, w którym model musi analizować zbyt wiele zmiennych naraz. Skutkuje to drastycznym wzrostem liczby pomyłek i

błędnych decyzji (odpowiednik człowieka pracującego na piętnastu monitorach jednocześnie).

- **Utrata zgodności celu (Alignment Loss):** Zjawisko stopniowego gubienia pierwotnego celu przez agenta w trakcie wielokrokowych operacji (np. zamiast optymalizować jakość rekrutacji, agent zaczyna optymalizować samą liczbę przejranych plików CV).

5. STANDARDY INTEGRACJI I SYSTEMY WIELOAGENTOWE (MAS)

Nowoczesna architektura odchodzi od jednego, potężnego agenta na rzecz rozproszonych ekosystemów.

MCP (Model Context Protocol)

Uniwersalny standard komunikacji, określany jako **"USB-C dla systemów AI"**. Zamiast budować dedykowany kod dla każdego zewnętrznego API i bazy danych, protokół MCP ujednolica warstwę integracyjną, drastycznie redukując złożoność kodu i czas wdrożenia.

Systemy wieloagentowe (Multi-Agent Systems - MAS)

Architektura oparta na zespole wyspecjalizowanych, odizolowanych agentów (np. Manager, HR, Finanse), współpracujących za pomocą protokołu **A2A (Agent-to-Agent)**. Podejście to oferuje trzy kluczowe zalety:

1. **Better Reasoning:** Wspólne rozwiązywanie problemów przez wyspecjalizowanych cyfrowych ekspertów.
2. **Responsibility Separation:** Ścisły podział odpowiedzialności – każdy agent operuje wyłącznie w swojej domenie.
3. **Context Efficiency:** Ograniczenie zużycia tokenów, ponieważ każdy komponent przetwarza tylko wycinek informacji.

MAS jako mechanizm obronny (Perspektywa Blue Team)

Systemy wieloagentowe stanowią kluczową warstwę bezpieczeństwa dzięki zastosowaniu dwóch fundamentalnych zasad:

- **Opaque Execution (Niejasne Wykonanie):** Agent przekazuje do kolejnego komponentu wyłącznie wynik końcowy i podjętą decyzję, bez ujawniania swojej pełnej pamięci operacyjnej oraz instrukcji systemowych.
- **Zasada Need-to-Know:** Każdy podagent otrzymuje absolutne minimum informacji niezbędnych do wykonania swojego zadania.

Analogia Militarna / Konstrukcyjna:

Architektura MAS działa jak **grodzie wodoszczelne w łodzi podwodnej**. Jeśli haker przeprowadzi udany atak *Indirect Prompt Injection* poprzez zainfekowane CV i przejmie kontrolę nad Agentem HR, dzięki izolacji kontekstu, *Opaque Execution* oraz barierom A2A, atak nie spenetruje reszty systemu. Jedna sekcja zostaje odcięta, ale cała jednostka nie tonie.

SŁOWNIK POJĘĆ ROZDZIAŁU 3 (ŚCIAĞA DO EGZAMINU)

Pojęcie	Definicja Techniczna	Rola w architekturze / Bezpieczeństwie
Agency	Zdolność do samodzielnego działania ku celowi.	Fundament autonomii; główna powierzchnia ataku.
RAG	Generowanie odpowiedzi oparte o wyszukiwanie.	Eliminuje halucynacje poprzez dostarczenie faktów do okna kontekstu.
Single Source of Truth	Jedno, zweryfikowane źródło prawdy.	Gwarancja spójności i determinizmu bazy wiedzy.
Token Bloat	Nadmierne rozrastanie się kontekstu.	Generuje wysokie koszty, opóźnienia i ryzyko błędów logicznych.
Alignment Loss	Utrata pierwotnego celu w pętli działań.	Ryzyko biznesowe; agent dryfuje w stronę błędnych metryk.
MCP	Model Context Protocol ("USB-C dla AI").	Standaryzacja połączeń między modelami a źródłami danych.
Opaque Execution	Ukrywanie wewnętrznego przebiegu procesów w A2A.	Mechanizm obronny; uniemożliwia eskalację i propagację ataku.
Need-to-Know	Dostęp do danych ograniczony do minimum.	Ścisła izolacja kontekstowa poszczególnych agentów w MAS.