

Najważniejsze pojęcia i ich znaczenie

Agent AI

System AI posiadający sprawczość — nie tylko odpowiada na pytania jak klasyczny LLM, ale potrafi podejmować decyzje, korzystać z narzędzi, wykonywać działania i reagować na zmiany środowiska.

Sprawczość (Agency)

Zdolność agenta do samodzielnego działania:

- planowania kroków,
- wyboru narzędzi,
- realizacji celu,
- podejmowania decyzji bez ciągłej ingerencji człowieka.

LLM (Large Language Model)

Model językowy generujący tekst na podstawie promptu użytkownika. Sam w sobie jest „pasywny” — nie wykonuje działań poza generowaniem odpowiedzi.

Agent Harness

Warstwa „otaczająca” LLM, która daje agentowi:

- dostęp do narzędzi,
- integracje z systemami,
- możliwość wykonywania operacji,
- pamięć i logikę działania.

To właśnie Harness zamienia LLM w agenta.

RAG (Retrieval-Augmented Generation)

Architektura, w której agent nie odpowiada wyłącznie z pamięci modelu, ale wyszukuje informacje w dokumentach, bazach wiedzy lub plikach.

Cel:

- ograniczenie halucynacji,
- zwiększenie jakości odpowiedzi,
- korzystanie z aktualnych danych.

Single Source of Truth

Jedno zaufane źródło wiedzy dla agenta AI.

Agent powinien opierać odpowiedzi wyłącznie na zatwierdzonych danych, a nie na „domysłach” modelu.

Halucynacje AI

Sytuacja, w której model generuje błędne lub zmyślane informacje, mimo że brzmią wiarygodnie.

Prompt Injection

Atak polegający na ukrywaniu złośliwych instrukcji w treści analizowanej przez agenta:

- stronie WWW,
- PDF,
- e-mailu,
- pliku tekstowym.

Agent może potraktować ukryte instrukcje jako polecenia systemowe.

Indirect Prompt Injection

Bardziej zaawansowana forma Prompt Injection, gdzie złośliwe instrukcje są ukryte pośrednio np. w:

- HTML,
- dokumentach,
- komentarzach,
- danych RAG.

RAG Poisoning

„Zatrucie” bazy wiedzy agenta fałszywymi lub manipulacyjnymi danymi.

Efekt:

- błędne decyzje,
- dezinformacja,
- utrata zaufania do systemu.

Memory Poisoning

Zatrutowanie pamięci długoterminowej agenta błędnymi informacjami, które później wpływają na kolejne odpowiedzi i działania.

Environment Drift

Zmiana środowiska działania systemu AI:

- nowe dane,
- nowe prompty,
- zmiany integracji,
- nowe pliki.

Może powodować:

- destabilizację,

- błędy,
- nieprzewidywalne zachowanie agentów.

Red Team

Zespół symulujący ataki na system AI:

- szuka podatności,
- testuje bezpieczeństwo,
- próbuje przejąć kontrolę nad agentem.

Blue Team

Zespół odpowiedzialny za obronę systemu:

- projektowanie zabezpieczeń,
- monitoring,
- reakcję na incydenty,
- tworzenie bezpiecznej architektury.

Defense in Depth

Strategia wielowarstwowego bezpieczeństwa.

Nie polega na jednym zabezpieczeniu, ale na wielu warstwach ochrony:

- kontrola dostępu,
- monitoring,
- walidacja danych,
- sandboxing,
- Human-in-the-Loop.

RBAC (Role-Based Access Control)

Mechanizm nadawania uprawnień według roli użytkownika.

Agent ma dostęp wyłącznie do danych i operacji przypisanych użytkownikowi.

Least Privilege

Zasada minimalnych uprawnień:

agent powinien mieć tylko taki dostęp, jaki jest absolutnie konieczny.

Human-in-the-Loop (HITL)

Człowiek zatwierdza krytyczne działania agenta:

- przelewy,
- usuwanie danych,
- operacje biznesowe.

MCP (Model Context Protocol)

Nowy standard komunikacji agentów AI z systemami i narzędziami zewnętrznymi.

Umożliwia:

- standaryzację integracji,
- dostęp do danych,
- komunikację między agentami i aplikacjami.

A2A (Agent-to-Agent)

Komunikacja pomiędzy agentami AI.

Agenci mogą:

- delegować zadania,
- wymieniać wyniki,
- współpracować w systemach wieloagentowych.

Multi-Agent Systems (MAS)

Architektura składająca się z wielu wyspecjalizowanych agentów współpracujących ze sobą.

Np.:

- Agent HR,
- Agent Finansowy,
- Agent Manager.

Opaque Execution

Model komunikacji, w którym agenci przekazują sobie wyłącznie wyniki działań, bez pełnego kontekstu i instrukcji.

Cel:

- ograniczenie propagacji ataku,
- izolacja zagrożeń.

Tool Overload

Sytuacja, gdy agent ma zbyt wiele narzędzi i integracji.

Efekty:

- spadek jakości działania,
- chaos decyzyjny,
- większe ryzyko błędów i manipulacji.

Compute Overhead

Ukryty koszt działania agentów AI:

- zużycie tokenów,
- koszt wywołań modeli,
- analiza narzędzi i kontekstu.

Routing

Mechanizm wyboru odpowiedniego modelu lub agenta do zadania.

Przykłady:

- prosty task → tani model,
- skomplikowana analiza → mocniejszy model.

Task-Based Routing

Routing oparty na rodzaju i złożoności zadania.

Cost-Aware Routing

Routing uwzględniający koszty działania modeli AI.

Needle in a Haystack

Problem „igły w stogu siana” — model gubi ważne informacje w ogromnym kontekście danych.

Rozwiązaniem jest m.in. RAG i selektywne wyszukiwanie kontekstu.

Code Interpreter

Izolowane środowisko wykonywania kodu:

- analiza danych,
- obliczenia,
- generowanie wykresów,
- przetwarzanie plików.

Computer Use

Agent operujący bezpośrednio na interfejsie komputera:

- klikanie,
- wpisywanie tekstu,
- obsługa GUI.

URL Context

Agent analizuje zawartość stron WWW jako źródło kontekstu.

Ryzyko:

- strony mogą zawierać ukryte instrukcje dla agenta.

Secure by Design

Projektowanie bezpieczeństwa od samego początku architektury systemu, a nie dopiero po wdrożeniu.